

Phát hiện Xâm nhập cho Điện toán Biên bằng Ensemble Stacking kết hợp Chiến lược lấy mẫu lai và Chung cất Tri thức

Nguyễn Vũ Thái*, Bùi Văn Dũng^{†‡}

^{*}Trường Đại học Giao thông Vận tải, Phân hiệu tại TP. Hồ Chí Minh

[†]Đại học Quốc gia TP. Hồ Chí Minh

[‡]Trường Đại học Công nghệ Thông tin

Email: nvthai@utc2.edu.vn, dungbv.17@grad.uit.edu.vn

Tóm tắt nội dung—Sự gia tăng mức độ phức tạp của các cuộc tấn công mạng đặt ra thách thức lớn cho Hệ thống Phát hiện Xâm nhập (IDS): vừa phải đạt độ chính xác cao đối với dữ liệu mất cân bằng, vừa phải tối ưu hóa tài nguyên để triển khai tại các thiết bị điện toán biên (edge computing). Để giải quyết bài toán đa mục tiêu này, nghiên cứu đề xuất kiến trúc IDS hai giai đoạn dành cho bài toán phân loại nhị phân trên tập dữ liệu CICIDS2017. Giai đoạn một xây dựng một mô hình Giáo viên (Teacher) dựa trên cơ chế Stacking (kết hợp XGBoost, LightGBM và Random Forest). Để xử lý mất cân bằng, dữ liệu huấn luyện được tối ưu bằng chiến lược lấy mẫu lai RUS (giảm lấy mẫu lớp đa số) và ENN (khử nhiễu ranh giới). Giai đoạn hai áp dụng kỹ thuật chưng cất tri thức (Knowledge Distillation) để chuyển giao tri thức từ Teacher sang một mô hình Học viên (Student) Cây quyết định tinh gọn. Kết quả thực nghiệm cho thấy mô hình Teacher đạt độ chính xác $> 99,8\%$. Đáng chú ý, mô hình Student sau chưng cất vẫn duy trì độ chính xác cao ($> 99\%$), đồng thời tăng tốc độ suy luận gấp 368 lần và nén dung lượng lưu trữ lên tới 1.758 lần. Giải pháp chứng minh tính hiệu quả và khả thi cho các hệ thống an ninh mạng thời gian thực trên thiết bị IoT.

Keywords—Intrusion Detection System, Edge Computing, Knowledge Distillation, Ensemble Learning, Extreme Data Imbalance, Hybrid Resampling, ENN, CICIDS2017.

I. Giới thiệu

Sự bùng nổ của Internet Vạn vật (IoT) và điện toán biên đã làm gia tăng đáng kể số lượng cũng như mức độ phức tạp của các cuộc tấn công mạng. Hệ thống Phát hiện Xâm nhập Mạng (NIDS) hiện đối mặt với ba thách thức lớn: (1) mất cân bằng dữ liệu nghiêm trọng, (2) yêu cầu phản hồi thời gian thực, và (3) hạn chế tài nguyên tại vùng biên. Các mô hình học sâu hiện tại có độ chính xác cao nhưng độ trễ suy luận lớn, trong khi các mô hình học máy truyền thống lại có tỷ lệ dương tính giả (FPR) cao đối với các tấn công hiếm gặp.

Để giải quyết bài toán này, chúng tôi đề xuất kiến trúc NIDS hai giai đoạn. Giai đoạn một (Hướng đến Độ chính xác), chúng tôi xây dựng mô hình Giáo viên (Teacher) sử dụng kiến trúc Stacking (kết hợp XGBoost, LightGBM, Random Forest), huấn luyện trên dữ liệu đã xử lý bằng bộ lọc lai RUS-ENN nhằm giảm thiểu tỷ lệ cảnh báo giả. Giai đoạn hai (Tối ưu cho Điện toán biên), kỹ thuật chưng cất tri thức (Knowledge Distillation) được áp dụng để chuyển giao tri thức từ mô hình Teacher sang một mô hình Học viên (Student) Cây quyết định nông, giúp giảm đáng kể kích thước mô hình và độ trễ suy luận.

Những đóng góp chính của bài báo bao gồm: (1) Ứng dụng quy trình tiền xử lý lai RUS-ENN trên CICIDS2017 để cải thiện khả năng nhận diện lớp thiểu số; (2) Đề xuất kiến trúc Stacking kết hợp boosting và bagging nhằm tối đa hóa độ chính xác; (3) Áp dụng chưng cất tri thức Teacher-Student giúp giảm độ trễ và chi phí bộ nhớ tại thiết bị biên; (4) Đánh giá thực nghiệm toàn diện, chứng minh sự cân bằng giữa hiệu năng và tính khả thi khi triển khai.

Cấu trúc bài báo: Phần II trình bày các nghiên cứu liên quan. Phần III mô tả phương pháp đề xuất. Phần IV và V phân tích thiết lập thực nghiệm và kết quả. Phần VI tóm tắt kết luận và hướng nghiên cứu tương lai.

II. Các nghiên cứu liên quan

Sự phát triển của NIDS hiện đại xoay quanh ba bài toán: xử lý mất cân bằng dữ liệu, tốc độ suy luận và tối ưu triển khai tại biên.

A. Kiến trúc học sâu lai và xu hướng tối ưu hóa vùng biên

Sự kết hợp các kiến trúc học sâu (CNN, LSTM, Attention) [1], [2] đã cải thiện đáng kể độ chính

xác nhưng lại gặp rào cản về độ trễ và tiêu thụ năng lượng. Để khắc phục, xu hướng nghiên cứu đang dịch chuyển sang thiết kế mạng tinh gọn. Các giải pháp như Autoencoder-LSTM [3] hay mạng học sâu lai tối giản [4] đã giúp giảm chi phí vận hành trên nền tảng nhúng (như Raspberry Pi).

B. Hệ thống phân tích thời gian thực và tái cân bằng dữ liệu

Các hệ thống NIDS thường sử dụng Apache Kafka và Spark Streaming [5] để duy trì tốc độ phân tích. Đồng thời, vấn đề mất cân bằng lớp được giải quyết bằng các mô hình sinh dữ liệu tiên tiến như TMG-GAN [6], [7], cho thấy hiệu quả trong việc khôi phục mẫu tấn công hiếm.

Mặc dù đã có nhiều bước tiến lớn, các nghiên cứu hiện tại vẫn chưa giải quyết trọn vẹn bài toán tối ưu đồng thời ba yếu tố: tối đa hóa độ chính xác, xử lý triệt để tình trạng mất cân bằng dữ liệu và đáp ứng yêu cầu độ trễ thấp của điện toán biên. Kiến trúc NIDS hai giai đoạn được đề xuất trong nghiên cứu này (tích hợp bộ lọc lai RUS-ENN, mô hình tổng hợp Stacking và chưng cất tri thức) được thiết kế nhằm khắc phục hoàn toàn những hạn chế nêu trên.

III. Kiến trúc và Phương pháp đề xuất

Nghiên cứu đề xuất kiến trúc hai giai đoạn: (1) Tiền xử lý dữ liệu với lấy mẫu lai RUS-ENN và huấn luyện mô hình Giáo viên (Stacking Teacher); (2) Áp dụng chưng cất tri thức (Knowledge Distillation) để chuyển giao tri thức từ Teacher sang mô hình Học viên (Student) Cây quyết định.

A. Xử lý nhiễu và phân phối dữ liệu

1) *Làm sạch và chuẩn hóa đặc trưng*: Dữ liệu CICIDS2017 được làm sạch (loại bỏ NaN, Inf, trùng lặp) và chuẩn hóa bằng Robust Scaling để giảm thiểu ảnh hưởng của ngoại lai:

$$x_{norm} = \frac{x_i - \tilde{x}}{IQR(X)} \quad (1)$$

trong đó $\tilde{x}$ là trung vị và $IQR(X)$ là khoảng tứ phân vị.

2) *Chiến lược lấy mẫu lai (RUS kết hợp ENN)*: Để giải quyết mất cân bằng lớn (lớp thiểu số < 0,01%), chúng tôi áp dụng chiến lược lấy mẫu lai. Đầu tiên, kỹ thuật Lấy mẫu giảm ngẫu nhiên (Random Under-Sampling - RUS) được sử dụng để giảm quy mô lớp đa số, loại bỏ bớt các mẫu cách xa ranh giới quyết định. Kế tiếp, bộ lọc ENN [9] loại bỏ các mẫu bị nhiễu cục bộ dựa trên quy tắc 3

láng giềng gần nhất. Quy trình này (Thuật toán 1) tạo ra tập dữ liệu cân bằng với ranh giới phân lớp sắc nét.

Thuật toán 1: Tiền xử lý và Lấy mẫu lai (RUS + ENN)

Đầu vào: Bộ dữ liệu thô $\mathcal{D} = \mathcal{S}_{maj} \cup \mathcal{S}_{min}$
Đầu ra : Bộ dữ liệu cân bằng $\mathcal{D}_{bal}$

- 1 Loại bỏ NaN, Inf, trùng lặp và chuẩn hóa Robust Scaler;
- 2 Giảm lấy mẫu $\mathcal{S}_{maj}$ bằng RUS để tạo $\mathcal{S}'_{maj}$;
- 3 Khởi tạo $\mathcal{D}_{bal} \leftarrow \mathcal{S}'_{maj} \cup \mathcal{S}_{min}$;
- 4 **foreach** $(x_i, y_i) \in \mathcal{S}'_{maj}$ **do**
- 5 Tìm 3 láng giềng gần nhất $N_3(x_i)$ trong $\mathcal{D}_{bal}$;
- 6 **if** nhãn đa số của $N_3(x_i) \neq y_i$ **then**
- 7 $\mathcal{D}_{bal} \leftarrow \mathcal{D}_{bal} \setminus \{(x_i, y_i)\}$;
- 8 **end**
- 9 **end**
- 10 **return** $\mathcal{D}_{bal}$

B. Mô hình Teacher kiến trúc Stacking

Kiến trúc Stacking gồm hai tầng:

1) *Tầng 0 (Nhóm mô hình cơ sở)*: Bao gồm **XGBoost** [10], **LightGBM** [11] (cơ chế boosting) và **Random Forest** [12] (cơ chế bagging).

2) *Tầng 1 (Mô hình tổng hợp)*: Đầu ra xác suất từ Tầng 0 tạo thành ma trận đặc trưng $Z_i = [P_{XGB}, P_{LGBM}, P_{RF}]$. Bộ phân loại Hồi quy Logistic tổng hợp dự đoán qua hàm sigmoid: $\hat{Y} = \sigma(W \cdot Z_i + b)$. Kiến trúc này tăng độ chính xác và giảm cảnh báo giả.

C. Chưng cất tri thức sang mô hình Student

Mô hình Stacking Teacher ($\mathcal{E}$) có độ trễ lớn, không phù hợp cho thiết bị biên. Do đó, chúng tôi áp dụng chưng cất tri thức dạng Mô hình thay thế (Surrogate Model) để huấn luyện một mô hình Student (Cây quyết định nông). Cây quyết định được chọn vì tính gọn nhẹ và tốc độ duyệt $O(\log n)$.

Cụ thể, mô hình Teacher tổng hợp nhãn mục tiêu mới $\hat{Y}_{teacher}$ bằng cách tạo ra các dự đoán nhãn cứng (hard labels) trên tập huấn luyện. Sau đó, mô hình Student $M_{student}$ học trực tiếp trên bộ nhãn này (Thuật toán 2).

IV. Thiết lập thực nghiệm

A. Môi trường phần cứng và phần mềm

Toàn bộ quá trình thực nghiệm (bao gồm huấn luyện mô hình Giáo viên và đánh giá tốc độ suy

Thuật toán 2: Chung cất tri thức Giáo viên - Học viên**Đầu vào:** Tập huấn luyện $X_{train} = \{x_1, \dots, x_N\}$, Mô hình Giáo viên $\mathcal{E}$ **Đầu ra :** Mô hình Học viên $M_{student}$

```

1 Khởi tạo mảng dự đoán  $\hat{Y}_{teacher} \leftarrow$  mảng
  rỗng kích thước  $N$ 
2 for  $i = 1 \dots N$  do
3    $p_i \leftarrow \mathcal{E}.predict\_proba(x_i)$ 
4    $\hat{Y}_{teacher}[i] \leftarrow \arg \max(p_i)$ 
5 end
6 Khởi tạo Cây quyết định  $M_{student}$ 
  ( $\max\_depth=d$ )
7  $M_{student}.fit(X_{train}, \hat{Y}_{teacher})$ 
8 return  $M_{student}$ 

```

luận của mô hình Học viên) đều được triển khai thống nhất trên nền tảng Google Colab Pro (Intel Xeon 2.20GHz, 13GB RAM, GPU NVIDIA Tesla T4 16GB). Hệ thống được cài đặt trên ngôn ngữ Python 3.10.12, kết hợp với các thư viện nền tảng bao gồm Scikit-learn 1.2.2 và Imbalanced-learn 0.10.1.

B. Kịch bản thực nghiệm và Đánh giá hiệu năng

Chuỗi thực nghiệm gồm ba kịch bản chính:

- 1) *Tác động của tiền xử lý:* Đánh giá hiệu quả phương pháp lai RUS-ENN so với dữ liệu nguyên bản.
- 2) *Năng lực phát hiện:* So sánh độ chính xác của Teacher với các kiến trúc học máy phổ biến.
- 3) *Đánh giá tài nguyên tại biên:* So sánh kích thước mô hình và độ trễ suy luận (ms) trên phần cứng CPU để làm rõ giá trị của chung cất tri thức.

Do tập dữ liệu mất cân bằng nghiêm trọng, việc đánh giá chỉ dựa trên Accuracy sẽ không phản ánh đúng hiệu năng của mô hình. Do đó, chúng tôi sử dụng **F1-Score** làm tiêu chuẩn định lượng chính. F1-Score là trung bình điều hòa giữa Precision (Độ chuẩn xác - khả năng giảm cảnh báo giả) và Recall (Độ nhạy - khả năng phát hiện tấn công thực tế).

V. Kết quả và Phân tích**A. Đánh giá tổng thể: Hiệu năng nhận diện và Độ trễ suy luận**

Bảng I tóm tắt hiệu năng phân loại và cấu hình tài nguyên của các mô hình trên tập kiểm thử độc lập.

Bảng I: So sánh tổng hợp về Hiệu năng, Độ trễ suy luận và Dung lượng lưu trữ

Mô hình	Acc.	F1	AUC	Trễ (ms/1k)	Size (MB)
XGBoost	0,9986	0,9960	0,9999	–	–
LightGBM	0,9987	0,9961	0,9999	–	–
Random Forest	0,9985	0,9957	0,9999	–	–
Stacking (Teacher)	0,9987	0,9963	0,9999	60189,94	22,50
Student (DT)	0,9948	0,9845	0,9992	163,62	0,0128


Bảng II: So sánh hiệu năng với các nghiên cứu gần đây trên CICIDS2017

Nghiên cứu	Phương pháp	Acc. (%)	F1 (%)
Amara et al. (2025) [13]	CNN+TCN+LSTM Ens.	99,99	100,0
Nguyen et al. (2024) [14]	Augmented WGAN + Ens.	99,78	–
Ding et al. (2024) [6]	TMG-GAN + DNN	99,81	99,72
Khan et al. (2024) [15]	SMOTE-Tomek + DT	99,96	–
Hu et al. (2024) [1]	Hybrid Attention	99,79	–
Ji (2025) [2]	GRU-ResCBANet	99,83	–
Sarhan et al. (2022) [16]	ML Baseline (TII)	99,70	99,20
Stacking Teacher	Hybrid Ensemble	99,87	99,63
Student (Chung cất)	DT Lightweight DT	99,48	98,45

Các số liệu minh chứng mô hình Stacking Teacher đạt hiệu năng rất cao (F1 0,9963). Đặc biệt, mô hình Student sau chung cất vẫn duy trì độ chính xác (F1 0,9845) nhưng mang lại ưu thế vượt trội khi triển khai: tốc độ suy luận tăng **368 lần** (giảm từ 60189,94 ms xuống 163,62 ms/1k mẫu) và nén dung lượng **1.758 lần** (từ 22,50 MB xuống 0,0128 MB).

B. Đường cong AUC-ROC/PR và Ma trận Nhầm lẫn

Hình 1 hiển thị hiệu suất qua đường cong ROC và PR. AUC-PR của Teacher đạt 0,9999, và Student duy trì ở mức 0,9992, cho thấy độ ổn định xuất



Hình 1: Đường cong ROC và Precision-Recall của các mô hình (hiển thị góc nhìn toàn cảnh và vùng phóng to).

sắc trên dữ liệu mất cân bằng. Ma trận nhầm lẫn (Hình 2) chỉ ra việc kết hợp kiến trúc Stacking với RUS-ENN đã giúp mô hình khắc phục triệt để tình trạng bỏ sót các cuộc tấn công (giảm thiểu False Negatives), đồng thời vẫn kiểm soát chặt chẽ tỷ lệ cảnh báo giả ở mức cực thấp.

C. Thử nghiệm Loại bỏ Thành phần (Ablation Study)


Thử nghiệm phân rã cho thấy: (1) Quá trình tiền xử lý RUS-ENN đóng vai trò quyết định giúp nâng cao năng lực phát hiện các lớp tấn công hiếm (tăng mạnh Recall), khắc phục điểm yếu bỏ sót tấn công của các mô hình cơ sở; (2) Mô hình phân loại tổng hợp trong Stacking mang lại độ chính xác vượt trội so với kỹ thuật Soft Voting truyền thống; (3) Việc tích hợp Random Forest giúp gia tăng tính đa dạng và cải thiện F1-score tổng thể.

D. So sánh với các nghiên cứu gần đây

Bảng II so sánh hiệu năng đề xuất với các nghiên cứu NIDS hiện đại (2024–2026). Giải pháp của chúng tôi đạt hiệu năng cạnh tranh với các mô hình học sâu phức tạp nhưng lại nhẹ và nhanh hơn vượt trội. Mô hình Student siêu nhẹ (0,0128 MB, 163,62 ms/1k mẫu) tạo sự cân bằng tối ưu giữa hiệu năng và tính khả thi khi triển khai trên IoT.

VI. Kết luận

Bài báo này đã đề xuất một giải pháp nhằm giải quyết đồng thời ba thách thức lớn của các Hệ thống Phát hiện Xâm nhập Mạng (NIDS) hiện nay: phân phối dữ liệu mất cân bằng lớn, yêu cầu về tốc độ phản hồi thời gian thực và rào cản phần cứng tại các thiết bị biên. Cốt lõi của giải pháp là một kiến trúc hai giai đoạn. Ở giai đoạn đầu, một mô hình Giáo viên (Teacher) dựa trên kiến trúc phân loại tổng hợp (Stacking) đã được thiết lập, kết hợp XGBoost, LightGBM và Random Forest. Nhờ việc được huấn



Hình 2: Ma trận Nhầm lẫn: Đối chiếu giữa các mô hình đơn lẻ và kiến trúc Stacking Teacher.

luyện trên không gian đặc trưng đã được xử lý bởi chiến lược lấy mẫu lai RUS-ENN, mô hình Teacher sở hữu khả năng nhận diện chính xác những mẫu tấn công hiếm gặp, đồng thời giảm thiểu tỷ lệ cảnh báo giả. Ở giai đoạn sau, kỹ thuật chưng cất tri thức (Knowledge Distillation) đã được sử dụng nhằm chuyển giao tri thức từ Teacher sang một mô hình Học viên (Student) là một mô hình Cây quyết định nông.

Thực nghiệm trên bộ dữ liệu kiểm chuẩn CICIDS2017 đã cung cấp những kết quả rõ ràng: mô hình Student không chỉ bảo toàn được độ chính xác tiệm cận với cấu trúc gốc (đạt F1 0,9845), mà còn mang lại sự cải thiện lớn về mặt hiệu năng vận hành khi giảm không gian lưu trữ tới 1.758 lần và tăng tốc độ suy luận lên 368 lần. Những kết quả này khẳng định tính khả thi của giải pháp trong các kịch bản triển khai an ninh mạng thời gian thực trên hệ sinh thái IoT.

Trong tương lai, định hướng nghiên cứu sẽ tập trung vào việc tích hợp Học máy Liên kết

(Federated Learning). Hướng tiếp cận này kỳ vọng sẽ mở ra cơ chế cập nhật mô hình Student liên tục và tự động từ các nút mạng phân tán, đảm bảo khả năng phòng ngự trước các biến thể tấn công mới mà vẫn tuân thủ nghiêm ngặt các tiêu chuẩn về quyền riêng tư dữ liệu mạng.

Phụ lục

Lời cảm ơn

Tác giả xin gửi lời cảm ơn tới Viện An ninh mạng Canada (Canadian Institute for Cybersecurity) đã cung cấp bộ dữ liệu CICIDS2017.

Tài liệu

- [1] X. Hu, X. Meng, S. Liu, and L. Liang, "An improved algorithm for network intrusion detection based on deep residual networks," *IEEE Access*, vol. 12, pp. 66432–66441, 2024.
- [2] C. Ji, H. Liu, and W. Dai, "Hybrid model for network traffic anomaly detection based on parallel two-stage feature fusion," *IEEE Access*, vol. 13, pp. 27310–27324, 2025.

- [3] S. M. Hejazi, A. Y. Alshalabi, M. Hatamleh, and E. Albaroudi, "A lightweight hybrid deep learning-based intrusion detection system for detecting botnet attacks in IoT networks," *Journal of Scientific Research and Reports*, vol. 31, no. 11, pp. 97–120, 2025.
- [4] R. H. Altaie and H. K. Hoomod, "An intrusion detection system using a hybrid lightweight deep learning algorithm," *Engineering, Technology & Applied Science Research*, vol. 14, no. 5, pp. 16 740–16 743, 2024.
- [5] K. M. K. Kumar, M. V. S. Reddy, K. Ullas, and S. Muthuraman, "Distributed intrusion detection system using kafka and spark streaming," in *2025 International Conference on Visual Analytics and Data Visualization (ICVADV)*. IEEE, 2025.
- [6] H. Ding, Y. Sun, N. Huang, Z. Shen, and X. Cui, "TMG-GAN: Generative adversarial networks-based imbalanced learning for network intrusion detection," *IEEE Transactions on Information Forensics and Security*, vol. 19, pp. 1156–1167, 2024.
- [7] S. M. Shamim, Y. Kodera, and Y. Nogami, "Gan-based ids system for imbalanced datasets in SDN environments with offline and real-time traffic analysis," *IEEE Access*, 2025.
- [8] N. V. Chawla, K. W. Bowyer, L. O. Hall, and P. J. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [9] D. L. Wilson, "Asymptotic properties of nearest neighbor rules using edited data," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 2, no. 3, pp. 408–421, 1972.
- [10] T. Chen and C. Guestrin, "Xgboost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [11] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "Lightgbm: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 2017.
- [12] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [13] M. Amara, N. Smairi, and M. Jaballah, "Stacked ensemble deep learning for robust intrusion detection in iot networks," in *Proceedings of the 17th International Conference on Agents and Artificial Intelligence - Volume 3: ICAART*. SciTePress, 2025, pp. 1146–1153.
- [14] H. V. Vo, H. P. Du, and H. N. Nguyen, "APELID: Enhancing real-time intrusion detection with augmented WGAN and parallel ensemble learning," *Computers & Security*, vol. 136, p. 103567, 2024.
- [15] F. A. Khan, A. A. Shah, N. Alshammry, S. Saif, W. Khan, M. O. Malik, and Z. Ullah, "Balanced multi-class network intrusion detection using machine learning," *IEEE Access*, vol. 12, pp. 178 222–178 236, 2024.
- [16] M. Sarhan, S. Layeghy, and M. Portmann, "Towards a standard feature set for network intrusion detection system datasets," *Mobile Networks and Applications*, vol. 27, no. 1, pp. 357–370, 2022.