

Phát hiện Xâm nhập cho Điện toán Biên bằng Ensemble Stacking kết hợp Chiến lược lấy mẫu lai và Chưng cất Tri thức

Nguyễn Vũ Thái

Phân hiệu tại TP. Hồ Chí Minh

Trường Đại học Giao thông Vận tải

TP. Hồ Chí Minh, Việt Nam

nvthai@utc2.edu.vn

Tóm tắt nội dung—Sự gia tăng mức độ phức tạp của các cuộc tấn công mạng đặt ra thách thức lớn cho Hệ thống Phát hiện Xâm nhập (IDS): vừa phải đạt độ chính xác cao trên dữ liệu mất cân bằng, vừa phải tối ưu tài nguyên để triển khai trên các thiết bị điện toán biên (edge computing). Để giải quyết bài toán đa mục tiêu này, nghiên cứu đề xuất kiến trúc IDS hai giai đoạn dành cho bài toán phân loại nhị phân trên tập dữ liệu CICIDS2017. Giai đoạn một xây dựng một mô hình Giáo viên (Teacher) dựa trên cơ chế Stacking (kết hợp XGBoost, LightGBM và Random Forest). Để khắc phục mất cân bằng, dữ liệu huấn luyện được tái cân bằng bằng chiến lược lấy mẫu lai RUS (giảm lấy mẫu lớp đa số) và ENN (làm sạch nhiễu ở vùng ranh giới). Giai đoạn hai áp dụng kỹ thuật chưng cất tri thức (Knowledge Distillation) để chuyển giao tri thức từ Teacher sang một mô hình Học sinh (Student) Cây quyết định nông. Kết quả thực nghiệm cho thấy mô hình Teacher đạt độ chính xác trên 99,8%. Đáng chú ý, mô hình Student sau chưng cất vẫn duy trì độ chính xác cao (trên 99%), đồng thời tăng tốc độ suy luận gấp 368 lần và giảm dung lượng lưu trữ tới 1.758 lần. Giải pháp cho thấy tính hiệu quả và khả thi cho các hệ thống an ninh mạng thời gian thực trên thiết bị IoT.

Title: Intrusion Detection for Edge Computing via a Stacking Ensemble with Hybrid Resampling and Knowledge Distillation

Author: Nguyen Vu Thai – University of Transport and Communications, Ho Chi Minh City Campus – nvthai@utc2.edu.vn

Abstract: The growing sophistication of cyberattacks poses a dual challenge for Intrusion Detection Systems (IDS): achieving high accuracy on highly imbalanced traffic while remaining lightweight enough for deployment on edge devices. To address this multi-objective problem, we propose a two-stage binary-classification IDS for the CICIDS2017 dataset. The first stage builds a Teacher model based on a Stacking ensemble (XGBoost, LightGBM, and Random Forest); to counter class imbalance, the training data is refined by a hybrid Random Under-Sampling (RUS) and Edited Nearest Neighbours (ENN) strategy. The second stage applies soft-label Knowledge Distillation, transferring the Teacher’s predicted-probability “dark knowledge” to a compact Decision Tree Student. Experiments show the Teacher reaches over 99.8% accuracy, while the distilled Student retains over

99% accuracy and substantially reduces inference latency and storage footprint, confirming the feasibility of real-time network security on resource-constrained IoT devices.

Keywords—Intrusion Detection System, Edge Computing, Knowledge Distillation, Ensemble Learning, Class Imbalance.

I. Giới thiệu

Sự bùng nổ của Internet Vạn vật (IoT) và điện toán biên đã làm gia tăng đáng kể số lượng cũng như mức độ phức tạp của các cuộc tấn công mạng. Hệ thống Phát hiện Xâm nhập Mạng (NIDS) hiện đối mặt với ba thách thức lớn: (1) mất cân bằng dữ liệu nghiêm trọng, (2) yêu cầu phản hồi thời gian thực, và (3) hạn chế tài nguyên tại vùng biên. Các mô hình học sâu hiện tại có độ chính xác cao nhưng độ trễ suy luận lớn, trong khi các mô hình học máy truyền thống lại có tỷ lệ cảnh báo giả (FPR) cao đối với các tấn công hiếm gặp.

Để giải quyết bài toán này, chúng tôi đề xuất kiến trúc NIDS hai giai đoạn. Giai đoạn một (Hướng đến Độ chính xác), chúng tôi xây dựng mô hình Giáo viên (Teacher) sử dụng kiến trúc Stacking (kết hợp XGBoost, LightGBM, Random Forest), huấn luyện trên dữ liệu đã xử lý bằng chiến lược lấy mẫu lai RUS-ENN nhằm giảm thiểu tỷ lệ cảnh báo giả. Giai đoạn hai (Tối ưu cho Điện toán biên), kỹ thuật chưng cất tri thức (Knowledge Distillation) được áp dụng để chuyển giao tri thức từ mô hình Teacher sang một mô hình Học sinh (Student) Cây quyết định nông, giúp giảm đáng kể kích thước mô hình và độ trễ suy luận.

Những đóng góp chính của bài báo bao gồm: (1) Ứng dụng quy trình tiền xử lý lai RUS-ENN trên CICIDS2017 để cải thiện khả năng nhận diện lớp thiểu số; (2) Đề xuất kiến trúc Stacking kết hợp boosting và bagging nhằm tối đa hóa độ chính xác; (3) Áp dụng chưng cất tri thức Teacher-Student giúp giảm độ trễ và chi phí bộ nhớ tại thiết bị biên; (4) Đánh giá thực nghiệm toàn diện, chứng minh sự cân bằng giữa hiệu năng và tính khả thi khi triển khai.

Cấu trúc bài báo: Phần II trình bày các nghiên cứu liên quan. Phần III mô tả phương pháp đề xuất. Phần IV và V phân tích thiết lập thực nghiệm và kết quả. Phần VI thảo luận và nêu các hạn chế. Phần VII tóm tắt kết luận và hướng nghiên cứu tương lai.

II. Các nghiên cứu liên quan

Sự phát triển của NIDS hiện đại xoay quanh ba bài toán cốt lõi: xử lý mất cân bằng dữ liệu, nâng cao độ chính xác phát hiện, và tối ưu triển khai tại vùng biên với tài nguyên hạn chế. Phần này điểm lại các hướng tiếp cận tiêu biểu theo ba trục đó.

A. Kiến trúc học sâu lai và tối ưu hóa vùng biên

Nhằm nâng cao độ chính xác, nhiều nghiên cứu kết hợp các kiến trúc học sâu như mạng tích chập (CNN), bộ nhớ dài-ngắn hạn (LSTM/GRU) và cơ chế chú ý (Attention) [1], [2] để trích xuất đồng thời đặc trưng không gian và thời gian của lưu lượng mạng. Mặc dù đạt độ chính xác cao, các mô hình này thường có số tham số lớn, độ trễ suy luận cao và tiêu thụ nhiều năng lượng, gây khó khăn khi triển khai trên thiết bị biên. Để khắc phục, xu hướng nghiên cứu đang dịch chuyển sang thiết kế mạng tinh gọn: các giải pháp như Autoencoder-LSTM [3] hay mạng học sâu lai tối giản [4] đã giảm đáng kể chi phí vận hành và được kiểm chứng trên nền tảng những như Raspberry Pi. Tuy nhiên, việc nén mô hình theo cách này thường đánh đổi một phần độ chính xác, đặc biệt với các lớp tấn công hiếm. Ở bối cảnh trong nước, hướng phát hiện tấn công IoT bằng học máy cũng được quan tâm: Thái và cộng sự [5] đề xuất kiến trúc IDS hai tầng (mô hình nhẹ tại gateway, mô hình phức tạp hơn trên máy chủ), còn Vũ và Nguyễn [6] khảo sát các kỹ thuật giảm chiều vector đặc trưng nhằm tăng hiệu quả tính toán cho mô hình phát hiện. Tuy vậy, các nghiên cứu này chưa khai thác chung cất tri thức để nén mô hình tổng hợp xuống mức triển khai trực tiếp tại biên.

B. Tái cân bằng dữ liệu và phân tích thời gian thực

Để duy trì tốc độ phân tích trên luồng dữ liệu lớn, các hệ thống NIDS thường tận dụng nền tảng xử lý dòng phân tán như Apache Kafka và Spark Streaming [7]. Song song, vấn đề mất cân bằng lớp—vốn làm suy giảm nghiêm trọng khả năng phát hiện tấn công hiếm—được giải quyết theo hai nhánh chính. Nhánh sinh dữ liệu sử dụng các mô hình đối kháng tạo sinh tiên tiến như TMG-GAN [8], [9] để tái tạo mẫu tấn công thiếu số, song chi phí huấn luyện cao và tiềm ẩn nguy cơ sinh ra mẫu thiếu thực tế. Nhánh lấy mẫu (sampling) gồm các kỹ thuật tăng/giảm mẫu; trong đó việc kết hợp giảm mẫu lớp đa số với lọc nhiễu ranh giới (như ENN) giúp tạo ranh giới phân lớp sắc nét với chi phí tính toán thấp hơn—là hướng mà nghiên cứu này kế thừa.

C. Học tổng hợp và Chung cất tri thức cho NIDS

Học tổng hợp (ensemble), đặc biệt là cơ chế Stacking [10], đã chứng tỏ hiệu quả vượt trội trong phát hiện xâm nhập nhờ kết hợp điểm mạnh của nhiều bộ phân loại cơ sở. Trên CICIDS2017, các kiến trúc stacking—từ tổ hợp học sâu CNN+TCN+LSTM [11] đến stacking kết hợp lựa chọn đặc trưng lai [12], [13]—đều đạt độ chính xác rất cao và tỷ lệ cảnh báo giả thấp. Tuy vậy, các mô hình tổng hợp này có kích thước và độ trễ lớn, khó triển khai trực tiếp tại biên. Chung cất tri thức (Knowledge Distillation) [14] là một hướng nén mô hình hứa hẹn, chuyển giao tri thức từ mô hình “Giáo viên”

phức tạp sang mô hình “Học sinh” gọn nhẹ; tuy nhiên phần lớn nghiên cứu hiện tập trung cho mạng nơ-ron, ít khai thác cho các bộ phân loại dạng cây—vốn đặc biệt phù hợp với thiết bị biên nhờ tốc độ suy luận nhanh và kích thước nhỏ.

Mặc dù đã có nhiều bước tiến, các nghiên cứu hiện tại vẫn chưa giải quyết trọn vẹn bài toán tối ưu *đồng thời* ba yếu tố: tối đa hóa độ chính xác, xử lý triệt để mất cân bằng dữ liệu, và đáp ứng yêu cầu độ trễ thấp của điện toán biên. Kiến trúc NIDS hai giai đoạn đề xuất trong nghiên cứu này—tích hợp chiến lược lấy mẫu lai RUS-ENN, mô hình tổng hợp Stacking và chung cất tri thức nhân mềm sang Cây quyết định—được thiết kế nhằm khắc phục đồng thời các hạn chế nêu trên.

III. Kiến trúc và Phương pháp đề xuất

Nghiên cứu đề xuất kiến trúc hai giai đoạn: (1) Tiền xử lý dữ liệu với lấy mẫu lai RUS-ENN và huấn luyện mô hình Giáo viên (Stacking Teacher); (2) Áp dụng chung cất tri thức (Knowledge Distillation) để chuyển giao tri thức từ Teacher sang mô hình Học sinh (Student) Cây quyết định.

A. Tiền xử lý và cân bằng dữ liệu

1) *Làm sạch và chuẩn hóa đặc trưng*: Dữ liệu CICIDS2017 được làm sạch (loại bỏ NaN, Inf, trùng lặp) và chuẩn hóa bằng Robust Scaling để giảm thiểu ảnh hưởng của các giá trị ngoại lai:

$$x_{norm} = \frac{x_i - \bar{x}}{IQR(X)} \quad (1)$$

trong đó $\bar{x}$ là trung vị và $IQR(X)$ là khoảng tứ phân vị.

2) *Chiến lược lấy mẫu lai (RUS kết hợp ENN)*: Để giải quyết mất cân bằng nghiêm trọng giữa lớp tấn công và lớp bình thường, chúng tôi áp dụng chiến lược lấy mẫu lai gồm hai bước. Đầu tiên, kỹ thuật Lấy mẫu giảm ngẫu nhiên (Random Under-Sampling – RUS) loại bỏ *ngẫu nhiên* (theo phân phối đều, không dựa trên khoảng cách) một phần mẫu của lớp đa số nhằm đưa hai lớp về quy mô tương đương và giảm chi phí tính toán cho bước sau. Kế tiếp, bộ lọc ENN [15] làm sạch ranh giới: với mỗi mẫu, nếu nhãn đa số trong 3 láng giềng gần nhất khác với nhãn của nó thì mẫu bị coi là nhiễu cục bộ và bị loại bỏ. Quy trình này (Thuật toán 1) tạo ra tập dữ liệu cân bằng với ranh giới phân lớp sắc nét. Lưu ý rằng toàn bộ quá trình lấy mẫu lai chỉ áp dụng trên tập huấn luyện; tập kiểm thử được giữ nguyên phân phối gốc để tránh rò rỉ dữ liệu.

B. Mô hình Teacher kiến trúc Stacking

Kiến trúc Stacking [10] gồm hai tầng:

1) *Tầng 0 (Nhóm mô hình cơ sở)*: Bao gồm **XGBoost** [16], **LightGBM** [17] (cơ chế boosting) và **Random Forest** [18] (cơ chế bagging).

2) *Tầng 1 (Mô hình tổng hợp)*: Đầu ra xác suất từ Tầng 0 tạo thành ma trận đặc trưng $Z_i = [P_{XGB}, P_{LGBM}, P_{RF}]$. Bộ phân loại Hồi quy Logistic tổng hợp dự đoán qua hàm sigmoid: $\hat{Y} = \sigma(W \cdot Z_i + b)$. Kiến trúc này tăng độ chính xác và giảm cảnh báo giả.

Thuật toán 1: Tiền xử lý và Lấy mẫu lai (RUS + ENN)

Đầu vào: Bộ dữ liệu thô $\mathcal{D} = \mathcal{S}_{maj} \cup \mathcal{S}_{min}$

Đầu ra : Bộ dữ liệu cân bằng $\mathcal{D}_{bal}$

- 1 Loại bỏ NaN, Inf, trùng lặp và chuẩn hóa Robust Scaler;
 - 2 Giảm lấy mẫu $\mathcal{S}_{maj}$ bằng RUS để tạo $\mathcal{S}'_{maj}$;
 - 3 Khởi tạo $\mathcal{D}_{bal} \leftarrow \mathcal{S}'_{maj} \cup \mathcal{S}_{min}$;
 - 4 **foreach** $(x_i, y_i) \in \mathcal{S}'_{maj}$ **do**
 - 5 Tìm 3 láng giềng gần nhất $N_3(x_i)$ trong $\mathcal{D}_{bal}$;
 - 6 **if** nhãn đa số của $N_3(x_i) \neq y_i$ **then**
 - 7 $\mathcal{D}_{bal} \leftarrow \mathcal{D}_{bal} \setminus \{(x_i, y_i)\}$;
 - 8 **end**
 - 9 **end**
 - 10 **return** $\mathcal{D}_{bal}$
-

C. Chung cất tri thức sang mô hình Student

Mô hình Stacking Teacher ($\mathcal{E}$) có độ trễ lớn, không phù hợp cho thiết bị biên. Do đó, chúng tôi áp dụng chung cất tri thức [14] với *nhãn mềm* (soft-label distillation) để chuyển giao tri thức sang một mô hình Student gọn nhẹ. Khác với việc chỉ sao chép nhãn cứng (hard label), nhãn mềm là xác suất dự đoán liên tục của Teacher, mang theo thông tin về độ tin cậy và mức độ gần ranh giới của từng mẫu (thường gọi là “dark knowledge”) — chính phần tri thức này giúp Student khái quát hóa tốt hơn.

Cụ thể, với mỗi mẫu x_i trong tập huấn luyện, Teacher sinh ra một mục tiêu mềm $p_i = \mathcal{E}.predict_proba(x_i)$ là xác suất thuộc lớp tấn công. Một Cây quyết định hồi quy (Decision Tree Regressor) $\mathcal{R}$ được huấn luyện để xấp xỉ hàm xác suất này; ở giai đoạn suy luận, dự đoán nhị phân được lấy bằng cách áp ngưỡng 0,5 lên đầu ra của $\mathcal{R}$ (Thuật toán 2). Cây quyết định được chọn làm Student vì tính gọn nhẹ và độ phức tạp suy luận $O(\log n)$. Để khẳng định giá trị của bước chung cất, chúng tôi còn so sánh Student chung cất với một Cây quyết định cùng cấu hình nhưng được huấn luyện trực tiếp trên nhãn gốc (không qua Teacher) trong phần thực nghiệm.

IV. Thiết lập thực nghiệm

A. Bộ dữ liệu CICIDS2017

Bộ dữ liệu CICIDS2017 do Viện An ninh mạng Canada (CIC) xây dựng, ghi lại lưu lượng mạng thực tế trong năm ngày làm việc với khoảng 2,83 triệu bản ghi luồng (flow). Mỗi luồng được trích xuất khoảng 80 đặc trưng thống kê bằng công cụ CICFlowMeter (thời lượng luồng, số gói, kích thước gói, cờ TCP, tốc độ byte/gói...). Dữ liệu bao gồm lưu lượng bình thường (BENIGN) và nhiều loại tấn công đa dạng: Brute Force (FTP/SSH), DoS/DDoS, PortScan, Web Attack, Infiltration, Botnet và Heartbleed.


Đặc điểm nổi bật của bộ dữ liệu là mất cân bằng nghiêm trọng (Hình 1): lưu lượng bình thường chiếm áp đảo (khoảng 80%), trong khi một số loại tấn công cực hiếm (ví dụ Heartbleed hay Infiltration chỉ có vài chục mẫu). Trong nghiên

Thuật toán 2: Chung cất tri thức nhãn mềm Giáo viên - Học sinh

Đầu vào: Tập huấn luyện $X_{train} = \{x_1, \dots, x_N\}$, Mô hình Giáo viên $\mathcal{E}$, ngưỡng $\tau = 0,5$

Đầu ra : Mô hình Học sinh $M_{student}$

- 1 Khởi tạo mảng mục tiêu mềm $P_{soft} \leftarrow$ mảng rỗng kích thước N
 - 2 **for** $i = 1 \dots N$ **do**
 - 3 $P_{soft}[i] \leftarrow \mathcal{E}.predict_proba(x_i)$ // xác suất lớp tấn công
 - 4 **end**
 - 5 Khởi tạo Cây quyết định hồi quy $\mathcal{R}$ (max_depth= d)
 - 6 $\mathcal{R}.fit(X_{train}, P_{soft})$ // học nhãn mềm
 - 7 Định nghĩa $M_{student}(x) = \mathbb{I}[\mathcal{R}(x) \geq \tau]$
 - 8 **return** $M_{student}$
-



Hình 1. Phân bố lớp trên CICIDS2017 (nhị phân): lưu lượng bình thường áp đảo so với tấn công.

cứ này, chúng tôi quy về bài toán phân loại nhị phân (BENIGN so với ATTACK); dù mức mất cân bằng ở dạng nhị phân nhẹ hơn so với đa lớp, việc nhận diện chính xác các mẫu thuộc những loại tấn công hiếm vẫn là thách thức mà chiến lược lấy mẫu lai RUS-ENN hướng tới giải quyết. Dữ liệu được chia thành tập huấn luyện và tập kiểm thử độc lập; mọi bước cân bằng chỉ áp dụng trên tập huấn luyện để tránh rò rỉ dữ liệu.

B. Môi trường phần cứng và phần mềm

Toàn bộ quá trình thực nghiệm (bao gồm huấn luyện mô hình Giáo viên và đánh giá tốc độ suy luận của mô hình Học sinh) đều được triển khai thống nhất trên nền tảng Google

Bảng I
Cấu hình siêu tham số chính của các mô hình

Mô hình	Siêu tham số
XGBoost	n_estimators=100; learning_rate=0,1; max_depth=6
LightGBM	n_estimators=100; learning_rate=0,1; max_depth=6
Random Forest	n_estimators=200; max_depth=20; min_samples_split=5; min_samples_leaf=2
Meta-learner Student (DT)	Hồi quy Logistic (class_weight=balanced); CV nội bộ=10 max_depth=8; min_samples_split=10

Colab Pro (Intel Xeon 2.20GHz, 13GB RAM, GPU NVIDIA Tesla T4 16GB). Hệ thống được cài đặt trên ngôn ngữ Python 3.10.12, kết hợp với các thư viện nền tảng bao gồm Scikit-learn 1.2.2 và Imbalanced-learn 0.10.1. Để đảm bảo khả năng tái lập, mọi thực nghiệm dùng chung một hạt giống ngẫu nhiên cố định (random_state=42). Cấu hình siêu tham số chính của các mô hình được tóm tắt trong Bảng I.

C. Kịch bản thực nghiệm và Đánh giá hiệu năng

Chuỗi thực nghiệm gồm ba kịch bản chính:

- 1) *Tác động của tiền xử lý*: Đánh giá hiệu quả phương pháp lai RUS-ENN so với dữ liệu nguyên bản.
- 2) *Năng lực phát hiện*: So sánh độ chính xác của Teacher với các kiến trúc học máy phổ biến.
- 3) *Đánh giá tài nguyên tại biên*: So sánh kích thước mô hình và độ trễ suy luận (ms) trên phần cứng CPU để làm rõ giá trị của chung cất tri thức.

Do tập dữ liệu mất cân bằng nghiêm trọng, việc đánh giá chỉ dựa trên Accuracy sẽ không phản ánh đúng hiệu năng của mô hình. Do đó, chúng tôi sử dụng **F1-Score** làm tiêu chuẩn định lượng chính. Gọi TP , FP , TN , FN lần lượt là số mẫu dương đúng, dương sai, âm đúng và âm sai. Các chỉ số được định nghĩa như sau:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad (2)$$

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}, \quad \text{FPR} = \frac{FP}{FP + TN}. \quad (3)$$

Trong đó Precision phản ánh khả năng giảm cảnh báo giả, còn Recall (độ nhạy) phản ánh khả năng phát hiện tấn công thực tế. Ngoài F1 của lớp tấn công, chúng tôi còn báo cáo *macro-F1* (trung bình F1 của hai lớp) để đánh giá công bằng trên dữ liệu mất cân bằng, cùng FPR để định lượng tỷ lệ cảnh báo giả.

V. Kết quả và Phân tích

A. Đánh giá tổng thể: Hiệu năng nhận diện và Độ trễ suy luận

Bảng II tóm tắt hiệu năng phân loại và cấu hình tài nguyên của các mô hình trên tập kiểm thử độc lập.

Các số liệu cho thấy mô hình Stacking Teacher đạt hiệu năng rất cao (F1 0,9963). Đặc biệt, mô hình Student sau chung cất vẫn duy trì độ chính xác (F1 0,9845) nhưng mang lại ưu thế vượt trội khi triển khai: tốc độ suy luận tăng **368 lần** (giảm từ 60189,94 ms xuống 163,62 ms/1k mẫu) và giảm dung lượng lưu trữ **1.758 lần** (từ 22,50 MB xuống 0,0128 MB).

Bảng II
So sánh tổng hợp về Hiệu năng, Độ trễ suy luận và Dung lượng lưu trữ

Mô hình	Acc.	F1	AUC	Trễ (ms/1k)	Size (MB)
XGBoost	0,9986	0,9960	0,9999	—	—
LightGBM	0,9987	0,9961	0,9999	—	—
Random Forest	0,9985	0,9957	0,9999	—	—
Stacking (Teacher)	0,9987	0,9963	0,9999	60189,94	22,50
Student (DT)	0,9948	0,9845	0,9992	163,62	0,0128

Bảng III
So sánh hiệu năng với các nghiên cứu gần đây trên CICIDS2017

Nghiên cứu	Phương pháp	Acc. (%)	F1 (%)
Amara et al. (2025) [11]	CNN+TCN+LSTM Ens.	99,99	100,0
Ji (2025) [2]	GRU-ResCBANet	99,83	—
Huang et al. (2025) [12]	Hybrid FS + Stacking	99,97	—
Jouybari et al. (2025) [13]	Filter FS + Stacking	99,79	—
Stacking Teacher	Hybrid Ensemble	99,87	99,63
Student DT (Chung cất)	Lightweight DT	99,48	98,45

Bảng IV
Hiệu năng theo từng lớp của mô hình Teacher (tập kiểm thử)

Lớp	Precision	Recall	F1
BENIGN (bình thường)	0,9996	0,9988	0,9992
ATTACK (tấn công)	0,9956	0,9984	0,9970
Trung bình macro	0,9976	0,9986	0,9981


Bảng V
So sánh các biến thể mô hình Student trên tập kiểm thử

Mô hình	Acc.	F1	F1-macro	Trễ (ms/1k)
Teacher (Stacking)	—	—	—	—
Student-Soft (chung cất)	—	—	—	—
Student-Hard (nhân cứng)	—	—	—	—
Student-Direct (không KD)	—	—	—	—

Bảng IV trình bày hiệu năng theo từng lớp của mô hình Teacher. Nhờ chiến lược lấy mẫu lai, mô hình đạt Precision và Recall cao và cân bằng ở cả hai lớp, thể hiện qua giá trị macro-F1 cao — chỉ số phản ánh đúng hơn Accuracy trên dữ liệu mất cân bằng vì nó xét đều cả lớp bình thường lẫn lớp tấn công.

B. So sánh các biến thể Student: giá trị của chung cất

Để khẳng định vai trò của bước chung cất, chúng tôi so sánh ba biến thể Student cùng cấu hình: *Student-Soft* (học nhần mềm từ Teacher), *Student-Hard* (học nhần cứng) và *Student-Direct* (huấn luyện trực tiếp trên nhãn gốc, không qua Teacher). Bảng V cho thấy chung cất nhần mềm đạt F1 cao nhất trong ba biến thể, xác nhận rằng tri thức xác suất của Teacher giúp Student khái quát hóa tốt hơn so với việc chỉ học nhần cứng hay nhần gốc.



Hình 2. Đường cong ROC và Precision-Recall của các mô hình (hiển thị góc nhìn toàn cảnh và vùng phóng to).

C. Đường cong AUC-ROC/PR và Ma trận Nhầm lẫn

Hình 2 hiển thị hiệu năng qua đường cong ROC và PR. AUC-ROC của Teacher đạt 0,9999, và Student duy trì ở mức 0,9992, cho thấy độ ổn định cao trên dữ liệu mất cân bằng. Ma trận nhầm lẫn (Hình 3) chỉ ra việc kết hợp kiến trúc Stacking với RUS-ENN đã giúp mô hình giảm mạnh tình trạng bỏ lọt tấn công (giảm thiểu False Negatives), đồng thời vẫn kiểm soát chặt chẽ tỷ lệ cảnh báo giả ở mức cực thấp.

D. Thử nghiệm Loại bỏ Thành phần (Ablation Study)

Bảng VI định lượng đóng góp của từng thành phần trong kiến trúc đề xuất. Kết quả cho thấy: (1) Quá trình tiền xử lý RUS-ENN đóng vai trò quyết định giúp nâng cao năng lực phát hiện các lớp tấn công hiếm (tăng mạnh Recall), khắc phục điểm yếu bỏ lọt tấn công của các mô hình cơ sở; (2) Mô hình phân loại tổng hợp trong Stacking mang lại độ chính xác vượt trội so với kỹ thuật Soft Voting truyền thống; (3) Việc tích hợp Random Forest giúp gia tăng tính đa dạng và cải thiện F1-score tổng thể.

Bảng VI
Thử nghiệm loại bỏ thành phần (đánh giá trên tập kiểm thử)


Cấu hình	Acc.	F1	FPR	AUC
Stacking, không ENN	0,9990	0,9976	0,000861	0,9999
Soft Voting + ENN	0,9987	0,9969	0,001373	0,9999
Stacking bỏ RF + ENN	0,9985	0,9965	0,001637	0,9999
Đề xuất (dữ 3 mô hình + ENN)	0,9987	0,9970	0,001191	0,9999

E. Độ ổn định qua kiểm chứng chéo


Để đánh giá độ ổn định của kiến trúc đề xuất, chúng tôi thực hiện kiểm chứng chéo phân tầng (Stratified K -Fold, $K = 5$) trên tập huấn luyện. Hình 4 biểu diễn giá trị trung bình kèm độ lệch chuẩn của các chỉ số qua các fold. Độ lệch chuẩn rất nhỏ trên tất cả chỉ số cho thấy mô hình ổn định, ít phụ thuộc vào cách phân chia dữ liệu và không có dấu hiệu quá khớp.

F. So sánh với các nghiên cứu gần đây

Bảng III so sánh hiệu năng đề xuất với các nghiên cứu NIDS hiện đại (2024–2026). Giải pháp của chúng tôi đạt hiệu



Hình 3. Ma trận Nhầm lẫn: Đối chiếu giữa các mô hình đơn lẻ và kiến trúc Stacking Teacher.



Hình 4. Độ ổn định qua kiểm chứng chéo K -Fold (trung bình $\pm$ độ lệch chuẩn).

năng cạnh tranh với các mô hình học sâu phức tạp nhưng lại nhẹ và nhanh hơn vượt trội. Mô hình Student siêu nhẹ (0,0128 MB, 163,62 ms/1k mẫu) tạo sự cân bằng tối ưu giữa hiệu năng và tính khả thi khi triển khai trên IoT.

VI. Thảo luận và Hạn chế

Điểm mạnh cốt lõi của giải pháp không nằm ở việc vượt qua các mô hình học sâu về độ chính xác tuyệt đối, mà ở *sự cân bằng giữa hiệu năng và chi phí triển khai*: mô hình

Student giữ được độ chính xác tiệm cận Teacher trong khi giảm hàng nghìn lần dung lượng và độ trễ, qua đó khả thi để triển khai trên thiết bị biên hạn chế tài nguyên.

Tuy vậy, nghiên cứu còn một số hạn chế cần lưu ý. Thứ nhất, độ trễ và dung lượng được đo trên CPU của nền tảng Google Colab (Intel Xeon), *chưa phải* phần cứng biên thực tế như Raspberry Pi hay vi điều khiển; các giá trị tuyệt đối có thể thay đổi khi triển khai trên thiết bị nhưng, dù tỷ lệ cải thiện giữa Teacher và Student được kỳ vọng vẫn giữ nguyên xu hướng. Thứ hai, bài báo giới hạn ở bài toán phân loại nhị phân (bình thường/tấn công); mức độ mất cân bằng và độ khó sẽ tăng đáng kể khi chuyển sang phân loại đa lớp theo từng loại tấn công cụ thể. Thứ ba, việc so sánh với các công trình khác (Bảng III) chỉ mang tính tham khảo, do khác biệt về giao thức đánh giá, cách chia dữ liệu và tiền xử lý giữa các nghiên cứu khiến việc đối chiếu trực tiếp khó tuyệt đối công bằng. Cuối cùng, kỹ thuật chưng cất nhân mềm hiện dùng cây hồi quy xấp xỉ xác suất của Teacher; các hướng như điều chỉnh nhiệt độ (temperature) hay chưng cất cho bài toán đa lớp vẫn còn đề ngỏ.

Về mặt triển khai thực tế, kích thước cực nhỏ của mô hình Student (khoảng 12,8 KB) cho phép nhúng trực tiếp vào các thiết bị tài nguyên hạn chế như cổng IoT hay vi điều khiển, trong khi độ phức tạp suy luận $O(\log n)$ của Cây quyết định giúp đạt thông lượng cao, phù hợp cho phát hiện ở tốc độ đường truyền. Một kịch bản triển khai hấp dẫn là kiến trúc

phân tầng: Student đóng vai trò bộ lọc tầng đầu tại biên để xử lý phần lớn lưu lượng với độ trễ thấp, còn những trường hợp mơ hồ mới được chuyển lên mô hình Teacher đầy đủ ở máy chủ/đám mây — qua đó cân bằng giữa độ trễ, chi phí truyền tải và độ chính xác.

Trong các hướng nghiên cứu tương lai, ngoài việc kiểm chứng trên phần cứng biên thực tế và mở rộng sang phân loại đa lớp, chúng tôi dự định khảo sát cơ chế cập nhật trực tuyến (online learning) để mô hình thích ứng với các biến thể tấn công mới, cũng như đánh giá tính bền vững của giải pháp trước các tấn công đối kháng (adversarial) nhằm vào bộ phát hiện.

VII. Kết luận

Bài báo này đã đề xuất một giải pháp nhằm giải quyết đồng thời ba thách thức lớn của các Hệ thống Phát hiện Xâm nhập Mạng (NIDS) hiện nay: dữ liệu mất cân bằng nghiêm trọng, yêu cầu về tốc độ phản hồi thời gian thực và hạn chế tài nguyên phần cứng tại các thiết bị biên. Cốt lõi của giải pháp là một kiến trúc hai giai đoạn. Ở giai đoạn đầu, một mô hình Giáo viên (Teacher) dựa trên kiến trúc phân loại tổng hợp (Stacking) đã được thiết lập, kết hợp XGBoost, LightGBM và Random Forest. Nhờ được huấn luyện trên dữ liệu đã được cân bằng bằng chiến lược lấy mẫu lại RUS-ENN, mô hình Teacher có khả năng nhận diện chính xác những mẫu tấn công hiếm gặp, đồng thời giảm thiểu tỷ lệ cảnh báo giả. Ở giai đoạn sau, kỹ thuật chưng cất tri thức (Knowledge Distillation) đã được sử dụng nhằm chuyển giao tri thức từ Teacher sang một mô hình Học sinh (Student) là một mô hình Cây quyết định nông.

Thực nghiệm trên bộ dữ liệu chuẩn CICIDS2017 đã cung cấp những kết quả rõ ràng: mô hình Student không chỉ bảo toàn được độ chính xác tiệm cận với mô hình gốc (đạt F1 0,9845), mà còn mang lại sự cải thiện lớn về mặt hiệu năng vận hành khi giảm không gian lưu trữ tới 1.758 lần và tăng tốc độ suy luận lên 368 lần. Những kết quả này khẳng định tính khả thi của giải pháp trong các kịch bản triển khai an ninh mạng thời gian thực trên hệ sinh thái IoT.

Trong tương lai, chúng tôi sẽ kiểm chứng giải pháp trên phần cứng biên thực tế (Raspberry Pi, vi điều khiển), mở rộng sang bài toán phân loại đa lớp, đồng thời khảo sát cơ chế cập nhật trực tuyến (online learning) và đánh giá tính bền vững trước các tấn công đối kháng (adversarial). Đặc biệt, hướng tích hợp Học liên kết (Federated Learning) hứa hẹn mở ra cơ chế cập nhật mô hình Student liên tục và tự động từ các nút mạng phân tán, đảm bảo khả năng phòng vệ trước các biến thể tấn công mới mà vẫn tuân thủ nghiêm ngặt các tiêu chuẩn về quyền riêng tư dữ liệu mạng.

Lời cảm ơn

Tác giả xin gửi lời cảm ơn tới Viện An ninh mạng Canada (Canadian Institute for Cybersecurity) đã cung cấp bộ dữ liệu CICIDS2017.

Tài liệu

- [1] X. Hu, X. Meng, S. Liu, and L. Liang, “An improved algorithm for network intrusion detection based on deep residual networks,” *IEEE Access*, vol. 12, pp. 66 432–66 441, 2024.

- [2] C. Ji, H. Liu, and W. Dai, “Hybrid model for network traffic anomaly detection based on parallel two-stage feature fusion,” *IEEE Access*, vol. 13, pp. 27 310–27 324, 2025.
- [3] S. M. Hejazi, A. Y. Alshalabi, M. Hatamleh, and E. Albaroudi, “A lightweight hybrid deep learning-based intrusion detection system for detecting botnet attacks in IoT networks,” *Journal of Scientific Research and Reports*, vol. 31, no. 11, pp. 97–120, 2025.
- [4] R. H. Altaie and H. K. Hoomod, “An intrusion detection system using a hybrid lightweight deep learning algorithm,” *Engineering, Technology & Applied Science Research*, vol. 14, no. 5, pp. 16 740–16 743, 2024.
- [5] M. T. Thái, H. H. Phạm, and T. N. Trần, “Hệ thống phát hiện xâm nhập hai tầng cho các mạng IoT sử dụng máy học,” *Tạp chí Khoa học Đại học Cần Thơ*, vol. 58, no. 2, pp. 43–50, 2022.
- [6] M. Q. Vũ và Đ. T. Nguyễn, “Thử nghiệm các phương pháp giảm số chiều vector đặc trưng khi sử dụng học máy để phát hiện tấn công mạng IoT,” *Tạp chí Khoa học và Công nghệ – Đại học Thái Nguyên*, vol. 230, no. 15, 2025.
- [7] K. M. K. Kumar, M. V. S. Reddy, K. Ullas, and S. Muthuraman, “Distributed intrusion detection system using kafka and spark streaming,” in *2025 International Conference on Visual Analytics and Data Visualization (ICVADV)*. IEEE, 2025.
- [8] H. Ding, Y. Sun, N. Huang, Z. Shen, and X. Cui, “TMG-GAN: Generative adversarial networks-based imbalanced learning for network intrusion detection,” *IEEE Transactions on Information Forensics and Security*, vol. 19, pp. 1156–1167, 2024.
- [9] S. M. Shamim, Y. Kadera, and Y. Nogami, “Gan-based ids system for imbalanced datasets in SDN environments with offline and real-time traffic analysis,” *IEEE Access*, 2025.
- [10] D. H. Wolpert, “Stacked generalization,” *Neural Networks*, vol. 5, no. 2, pp. 241–259, 1992.
- [11] M. Amara, N. Smairi, and M. Jaballah, “Stacked ensemble deep learning for robust intrusion detection in iot networks,” in *Proceedings of the 17th International Conference on Agents and Artificial Intelligence - Volume 3: ICAART*. SciTePress, 2025, pp. 1146–1153.
- [12] Y. Huang, G. Chen, J. Gou, Z. Fan, and Y. Liao, “A hybrid feature selection and aggregation strategy-based stacking ensemble technique for network intrusion detection,” *Applied Intelligence*, vol. 55, no. 1, p. 28, 2025.
- [13] S. M. Hashemi Jouybari, A. Janbaz, and A. Esfandiari, “A multivariate filter feature selection and stacking-based ensemble learning algorithm for network intrusion detection,” *The Journal of Supercomputing*, vol. 81, no. 1, p. 1129, 2025.
- [14] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” *arXiv preprint arXiv:1503.02531*, 2015.
- [15] D. L. Wilson, “Asymptotic properties of nearest neighbor rules using edited data,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 2, no. 3, pp. 408–421, 1972.
- [16] T. Chen and C. Guestrin, “Xgboost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [17] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “Lightgbm: A highly efficient gradient boosting decision tree,” in *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, 2017.
- [18] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.